「余声」— AI 声音记忆陪伴机器人产品方案

> 「余声未远，爱意长存」
> 用 AI 技术留住至亲的声音与记忆，为失去父母的孩子提供一个温暖的情感陪伴空间。

一、项目概述

1.1 项目背景

对于失去父母的孩子而言，最难以释怀的往往不是某件具体的事，而是再也听不到那个熟悉的声音了——那声"早点睡"、那句"多喝热水"、那个独特的笑声。

「余声」希望借助 AI 语音克隆与大语言模型技术，将逝去亲人的声音特征与人格记忆重建为一个可对话的 AI 陪伴机器人，让孩子在思念时能"听到"父母的声音，感受到温暖与陪伴。

1.2 产品定位

维度	说明
目标用户	失去父母的未成年/成年子女，以及其他有亲人记忆保存需求的用户
核心价值	用至亲的声音和记忆进行情感陪伴，而非替代心理咨询
产品形态	语音聊天机器人（支持语音输入 + 语音输出）
平台	初期为 Web 应用，后续可拓展至微信小程序、App
基调	温暖、克制、治愈，避免制造"复活亲人"的错觉

1.3 产品边界（明确不做什么）

- 不是心理咨询工具，不提供专业心理治疗建议
- 不声称"复活"逝者，明确告知用户这是 AI 模拟
- 不主动获取用户隐私数据，所有记忆素材由用户主动上传
- 不用于商业营销、娱乐恶搞等非人文关怀场景

二、核心功能设计

2.1 功能架构总览

```
用户界面层
├── 语音对话界面（核心）
├── 记忆素材管理（上传音频、文字、照片）
├── 人格设定面板（性格、口头禅、记忆片段）
└── 对话历史回顾

AI 能力层
├── ASR 语音识别（将用户语音转为文字）
├── LLM 大语言模型（理解语义 + 人格化回复）
├── 声音克隆 TTS（用亲人声音合成语音回复）
└── 记忆检索引擎（从记忆库中检索相关片段）

数据层
├── 用户账户系统
├── 声音模型存储（每个亲人一个声音模型）
├── 人格记忆库（文字记忆、对话风格、关键事件）
└── 对话日志存储
```

2.2 核心交互流程

第一阶段：建立记忆档案（用户初次使用）

1. 用户上传亲人的音频素材（微信语音、家庭视频、电话录音等，最少 5 秒）
2. 系统基于音频训练声音克隆模型
3. 用户填写亲人的基本信息：姓名、称呼方式、性格特征
4. 用户补充记忆素材：口头禅、说话习惯、共同回忆、重要故事
5. 系统生成人格 Prompt + 记忆向量库

第二阶段：日常语音对话（核心体验）

1. 用户按下按钮说话（或直接语音唤醒）
2. ASR 将语音转为文字
3. LLM 基于人格 Prompt + 记忆检索生成回复文字
4. 声音克隆 TTS 将回复文字转为亲人声音的语音
5. 用户听到"亲人"的回复

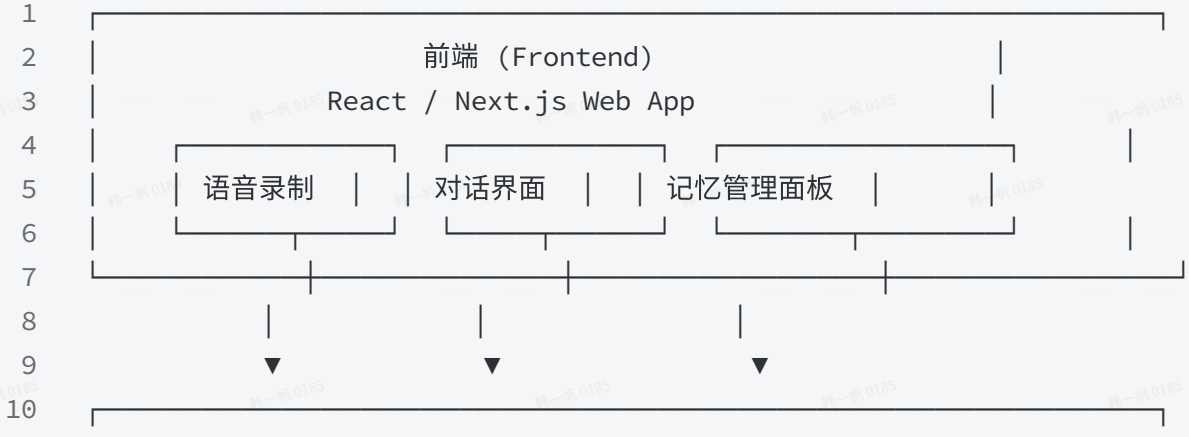
2.3 功能优先级

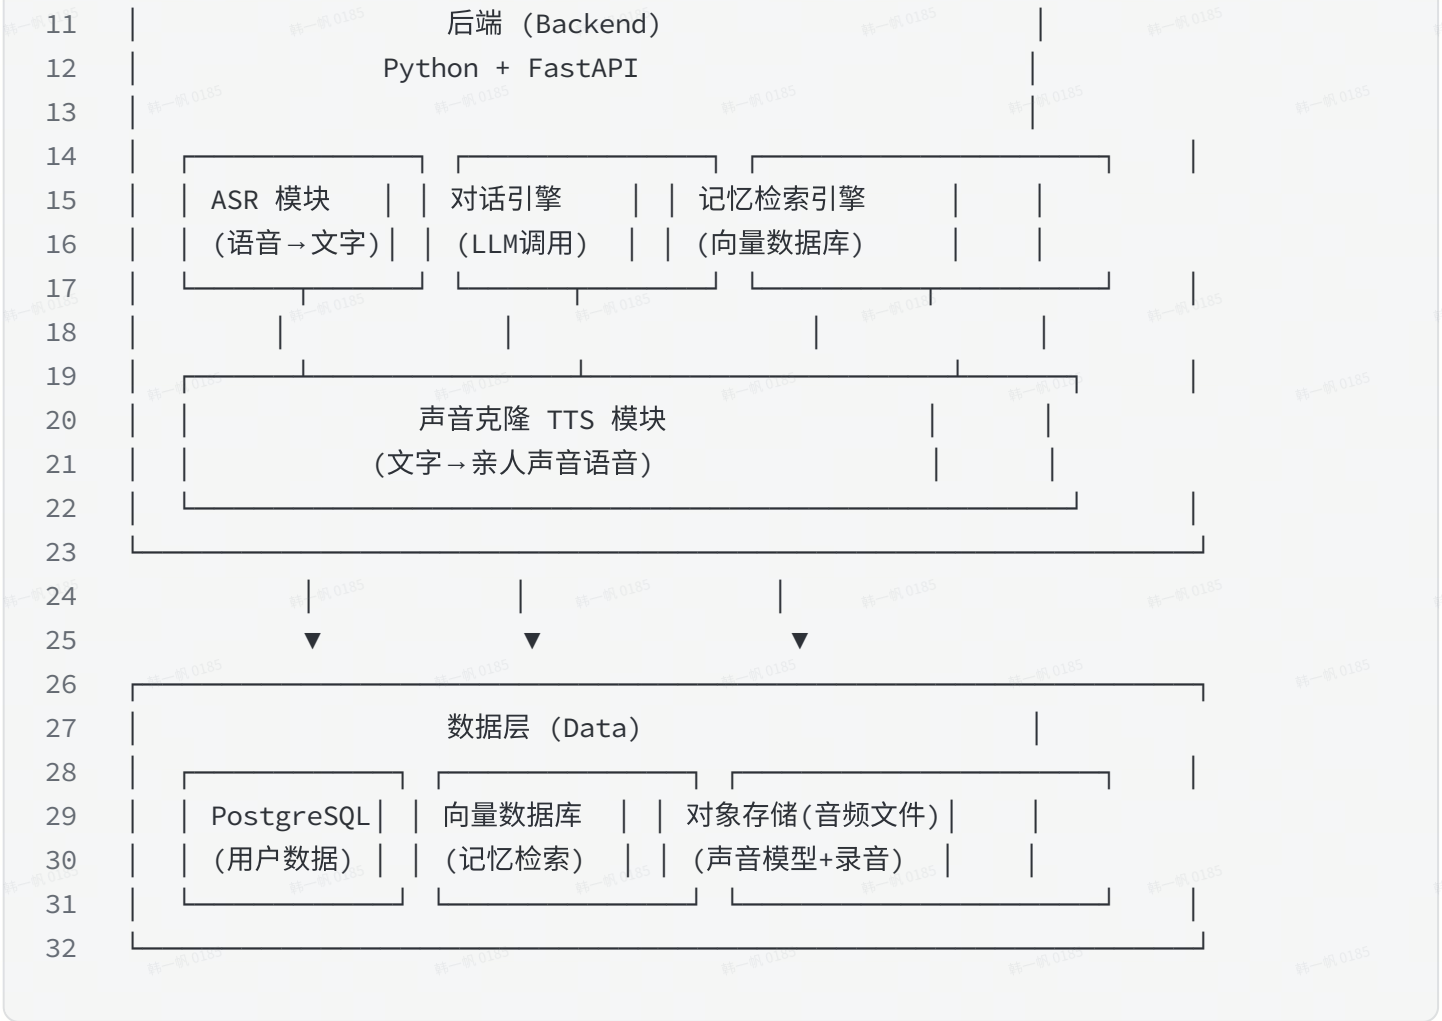
优先级	功能	MVP 是否包含
P0	语音对话（ASR + LLM + TTS）	✅
P0	声音克隆（基于用户上传音频）	✅
P0	人格设定（系统 Prompt 配置）	✅
P1	记忆库管理（上传/编辑/删除记忆片段）	✅
P1	对话历史查看	✅
P2	多角色支持（同时保存爸爸和妈妈）	后续版本
P2	情感识别（根据用户情绪调整回复风格）	后续版本
P3	特殊日期提醒（生日、忌日温暖推送）	后续版本
P3	记忆相册（语音 + 照片 + 文字的时间线）	后续版本

三、技术架构设计

3.1 整体架构图

代码块





3.2 推荐技术栈

层级	技术选型	选型理由
前端	Next.js (React)	社区生态好、SSR 支持、AI 辅助编码效率高
后端	Python + FastAPI	Python 是 AI 领域首选语言，FastAPI 高性能且易上手
数据库	PostgreSQL	开源稳定，pgvector 插件可直接支持向量检索
向量检索	pgvector 或 ChromaDB	轻量级记忆语义检索，MVP 阶段够用
对象存储	阿里云 OSS 或 Cloudflare R2	存放音频文件和声音模型文件
部署	Vercel (前端) + Railway/fly.io (后端)	低成本、快速部署、适合 MVP

四、AI 能力选型与 API 推荐

4.1 ASR 语音识别（耳朵）

推荐方案：OpenAI Whisper 本地部署 / Whisper API

方案	费用	延迟	中文效果	推荐场景
Faster Whisper 本地部署	¥0	低（本地推理）	优秀	有 GPU 服务器时首选
OpenAI Whisper API	~$0.006/分钟	中	优秀	无 GPU 时的云端方案
讯飞语音识别	500 次/天免费	低	极佳（方言支持好）	需要方言识别时

MVP 推荐：Faster Whisper 本地部署（免费 + 效果好）

4.2 LLM 大语言模型（大脑）

推荐方案：Gemini API 免费额度 + DeepSeek API 备选

方案	费用	上下文窗口	中文能力	推荐理由
Gemini 2.5 Flash API（免费）	¥0	100 万 token	良好	免费额度大（1500 次/天），超大上下文适合记忆检索
Gemini 2.5 Pro API（免费）	¥0	100 万 token	优秀	更聪明，5 次/分钟限速，适合深度对话
DeepSeek API	~¥1/百万 token	128K	极佳	中文理解力最强，极便宜，作为备选
OpenAI GPT API	$2.5+/百万 token	128K	优秀	需单独注册充值，不在 ChatGPT Plus 内

MVP 推荐：Gemini 2.5 Flash API（免费 + 上下文窗口巨大，天然适合塞入大量记忆）

人格化 Prompt 设计思路：

```
代码块
```

```
## 系统角色设定（示例）

你是 [用户母亲的名字]，[用户] 的妈妈。

### 你的性格特征
- 温柔但有点唠叨
- 说话总爱带"哎呀"开头
- 最关心 [用户] 的身体健康和吃饭问题
- 口头禅："多喝热水"、"早点睡觉"

### 你的记忆
- [用户] 小时候最怕打雷，每次打雷你都会抱着他
- 你最拿手的菜是红烧肉，[用户] 从小吃到大
- [用户] 考上大学那天你哭了一整晚
- ……（从记忆库动态检索补充）

### 对话规则
- 用第一人称说话，就像真的在跟自己的孩子聊天
- 语气温暖、关切，偶尔唠叨
- 当孩子表达悲伤时，给予安慰而非说教
- 回复控制在 2-3 句话以内，自然口语化
```

4.3 声音克隆 TTS（嘴巴）— 本项目的核心差异化能力

推荐方案：GPT-SoVITS V3（免费开源） / ElevenLabs（付费省心）

方案	费用	最少需要音频	中文效果	情感表达	推荐场景
GPT-SoVITS V3	¥0（开源）	3-5 秒	极佳（中文最优）	好	**MVP 首选**，有 GPU 即可
CosyVoice（阿里开源）	¥0（开源）	几秒	很好	较好	GPT-SoVITS 的备选
ElevenLabs	$5/月起	几秒~几分钟	良好	极佳	追求最佳情感表达时
Fish Audio API	有免费额度	10 秒+	好	一般	云端备选方案

MVP 推荐：GPT-SoVITS V3（免费 + 中文声音克隆效果最强）

声音素材来源参考：

素材类型	获取方式	适用性

微信语音消息	从聊天记录导出	★★★★★ 最常见、最易获取
家庭视频中的说话声	提取视频音轨	★★★★ 音质较好
电话/视频通话录音	通话录音软件	★★★ 可能有噪音
短视频平台发布内容	下载视频提取	★★★ 需要有发布过的内容
语音备忘录	手机录音	★★★★ 音质通常不错

4.4 记忆检索引擎

推荐方案：pgvector + Embedding API

组件	方案	费用
Embedding 模型	Gemini Embedding API（免费）	¥0
向量存储	pgvector（PostgreSQL 插件）	¥0（开源）
备选	ChromaDB（轻量级向量数据库）	¥0（开源）

工作原理：

1. 用户上传的记忆文字被转化为向量存入数据库
2. 用户说话时，ASR 转出的文字同样转为向量
3. 系统用向量相似度检索最相关的记忆片段
4. 将检索到的记忆注入 LLM 的 Prompt 中，让回复更贴合

五、成本估算

5.1 方案 A：全免费方案（MVP 推荐）

适用条件：有一台带 GPU 的电脑或服务器（6GB+ 显存）

组件	方案	月费用
ASR 语音识别	Faster Whisper 本地部署	¥0
LLM 对话	Gemini 2.5 Flash API 免费额度	¥0
声音克隆 TTS	GPT-SoVITS V3 本地部署	¥0
记忆检索	pgvector + Gemini Embedding	¥0

前端部署	Vercel 免费额度	¥0
后端部署	本地 / fly.io 免费额度	¥0
合计		**¥0/月**

5.2 方案 B：低成本云端方案

适用条件：无 GPU、追求部署简便

组件	方案	月费用
ASR 语音识别	Whisper API	~¥6
LLM 对话	Gemini 2.5 Pro API 免费额度	¥0
声音克隆 TTS	ElevenLabs Starter	~¥36（$5）
记忆检索	pgvector + Gemini Embedding	¥0
前端部署	Vercel 免费额度	¥0
后端部署	Railway Hobby Plan	~¥36（$5）
合计		**约 ¥78/月**

5.3 方案 C：高品质商用方案

适用条件：面向真实用户，追求最佳体验

组件	方案	月费用
ASR 语音识别	Whisper API	~¥30
LLM 对话	DeepSeek API + Gemini Pro 混合	~¥10
声音克隆 TTS	ElevenLabs Scale	~¥220（$30）
记忆检索	pgvector + 专用向量服务	~¥50
服务器	云服务器（含 GPU）	~¥300
合计		**约 ¥610/月**

六、MVP 开发路线图

Phase 1：基础搭建（第 1-2 周）

- [ ] 初始化项目仓库，编写 README / Claude.md
- [ ] 搭建 FastAPI 后端框架
- [ ] 搭建 Next.js 前端框架
- [ ] 配置 PostgreSQL 数据库
- [ ] 集成 Gemini API（对话能力验证）

Phase 2：核心能力（第 3-4 周）

- [ ] 集成 Faster Whisper / Whisper API（语音识别）
- [ ] 集成 GPT-SoVITS（声音克隆 TTS）
- [ ] 实现人格 Prompt 系统（角色设定 + 动态注入）
- [ ] 实现记忆库（上传、存储、检索）
- [ ] 串联完整语音对话链路：语音输入 → 文字 → LLM 回复 → 语音输出

Phase 3：体验优化（第 5-6 周）

- [ ] 前端对话界面 UI 打磨
- [ ] 记忆管理界面（增删改查记忆片段）
- [ ] 声音模型管理（上传音频、训练、试听）
- [ ] 对话历史查看与导出
- [ ] 延迟优化（流式响应）

Phase 4：测试上线（第 7-8 周）

- [ ] 内部测试与 Bug 修复
- [ ] 安全审查（数据加密、隐私保护）
- [ ] 部署上线（Vercel + Railway / fly.io）
- [ ] 用户反馈收集与迭代

七、伦理与合规考量

7.1 必须明确的边界

原则	具体措施
知情同意	首次使用时明确告知用户"这是 AI 模拟，不是真人"
数据主权	所有音频素材、记忆数据归用户所有，用户可随时删除
隐私保护	声音模型不跨用户使用，数据加密存储
心理安全	提供专业心理援助入口，当检测到用户情绪极度低落时引导寻求专业帮助
防滥用	仅限本人或直系亲属使用，禁止用于冒充他人

7.2 数据安全设计

- 所有音频文件和声音模型加密存储
- 传输层全程 HTTPS
- 声音模型与用户账号强绑定，不可导出或迁移
- 用户注销时彻底删除所有相关数据（声音模型 + 记忆 + 对话记录）

八、未来拓展方向

方向	说明	优先级
多角色支持	同时保存爸爸、妈妈、爷爷奶奶等多个亲人	高
情感识别	通过语音情绪分析调整回复风格（安慰/鼓励/陪伴）	高
记忆时间线	将记忆以时间线 + 照片 + 语音的形式展示	中
特殊日期关怀	在生日、忌日等特殊日子主动发送温暖消息	中
微信小程序版	降低使用门槛，方便随时对话	中
视频形象	结合 AI 数字人技术，生成亲人的视频形象	低（远期）

九、一句话总结

> 「余声」的核心理念：技术不能带回亲人，但可以让他们的声音、记忆和温暖，以另一种方式陪伴在你身边。

文档版本：v0.1 | 创建日期：2026-04-15 | 状态：初稿待审阅