「余声」产品方案修订版

PRD + 低成本技术方案（加入粤语/普通话双模识别与方言声音输出）

版本：v0.2（修改版）
适用段：MVP / 首轮验证 / 小规模内测

核心原则：保持原方案低成本路线不变，优先增强“方言识别”和“方言声音体验”，避免一次性引入高成本云服务与复杂多角色能力。

> ***修订摘要***
> *1. 第一阶段明确支持粤语/普通话双模识别；*
> *2. 第三层目标改为：尽量用亲人的方言声音说出来，但以“受素材质量约束的增强能力”定义，而不是无限承诺“完全复原”；*
> *3. 保持 Next.js + FastAPI + PostgreSQL/pgvector + Faster Whisper/Gemini/GPT-SoVITS 的低成本架构；*
> *4. 新增方言素材要求、方言 persona schema、分层记忆检索、风控与失败场景处理。*

---

1. 修订后的产品定位

产品定位：用 AI 技术留住至亲的声音、说话方式与关键记忆，为用户提供克制、可信、可持续使用的纪念型语音陪伴体验。

首期目标用户：优先聚焦成年用户，且由本人上传已故直系亲属素材。这样可以降低授权、监护与高风险心理场景的复杂度。

核心价值：不是“复活亲人”，而是在明确的 AI 模拟边界内，尽量还原“熟悉的声音、熟悉的表达、熟悉的关心方式”。

首期差异化：在低成本方案下，优先支持粤语/普通话双模识别，并逐步实现“用亲人的方言声音说出来”的体验。

1.1 本次修订重点

模块	原方案	修订后定义
识别层	中文语音识别	第一阶段明确支持粤语/普通话双模识别
生成层	人格化回复	在 persona schema 中增加 dialect_style（方言词汇、句式、称呼、语气）

语音输出层	亲人声音合成	目标升级为“方言声音增强输出”，受素材质量和方言类型约束
风控层	泛化描述	新增授权校验、方言素材评分、失败提示与情绪安全降级

2. MVP 范围与优先级

P0：单角色记忆档案、普通话/粤语双模 ASR、LLM 对话、亲人声音合成、基础记忆检索、对话历史。

P1：方言 persona 配置、方言素材评分、方言输出增强、记忆管理面板、试听与质量提示。

P2：多角色支持、情感识别、特殊日期提醒、记忆时间线。

P3：视频形象、微信小程序、复杂多终端同步。

2.1 不做什么

- 不承诺“完全复原”亲人，也不将系统描述为真人在线存在。
- 不把心理援助功能包装成专业治疗；极端情绪场景下以安全转介优先。
- 首版不支持开放式公众模仿，不支持在世且未授权人物的声音克隆。
- 首版不承诺全国方言全覆盖，只优先支持粤语/普通话双模识别，并为部分方言输出能力做增强。

3. 关键用户场景

场景	用户意图	系统重点	首版优先级
想念爆发时	想听到熟悉声音获得安慰	快速首响、语言风格像本人、避免出戏	高
睡前/节日/纪念日	想获得熟悉叮嘱或陪伴	短回复、温柔口吻、可调用高频记忆	高
回忆过去	想听对某段经历的回应	检索相关记忆片段并注入对话	中
方言交流	希望系统听懂粤语并以亲人的方言声音回应	双模识别 + 方言 persona + 方言 TTS 增强	高

4. PRD：核心功能需求

4.1 建立记忆档案

- 上传音频素材：支持微信语音、家庭视频抽取音轨、电话录音、语音备忘录。
- 方言标注：上传时允许用户勾选“普通话 / 粤语 / 混合 / 其他待扩展方言”。
- 素材质量检测：时长、噪音、静音比例、说话人纯度、方言覆盖度、是否适合训练方言输出。

- 基础信息录入：称呼、关系、性格、常用口头禅、关心主题、禁忌表达。
- 记忆录入：高频关系记忆、事件记忆、安慰模板、常见问答、方言表达版本。

4.2 日常语音对话

- 交互模式：首版采用 push-to-talk，不做语音唤醒。
- 识别模式：用户可选择“普通话模式 / 粤语模式 / 自动推荐（内测阶段仅推荐，不默认自动）”。
- 回复生成：LLM 基于 persona schema + 分层记忆检索输出短句、口语化内容。
- 语音输出：优先用亲人声音合成；当方言素材充足时启用方言增强输出；不足时退化为“亲人音色 + 偏普通话文本”。
- 失败提示：若识别置信度低、方言输出不稳定或素材不足，给出明确解释与补充建议。

4.3 Persona Schema（新增结构化人设）

字段	说明	示例
identity	身份与关系	妈妈 / 爸爸 / 外婆
self_name / user_name	自称与称呼	妈妈；阿女 / 阿仔 / 宝宝
style	语言风格	温柔、短句、偶尔唠叨
dialect_style	方言词汇与句式	粤语高频词、句尾语气、固定称呼
care_topics	高频关心主题	吃饭、睡觉、工作压力、天气
memory_core	恒定关系记忆	小时候怕打雷、最喜欢某道菜
comfort_rules	安慰策略	先共情，再提醒休息，不说教

4.4 分层记忆系统（比单纯向量库更稳）

- 基础人设层：每次对话固定注入，不参与相似度检索。
- 高频关系层：称呼、口头禅、日常叮嘱、固定安慰语。
- 事件记忆层：具体故事、时间点、共同经历，按相似度检索。
- 安全规则层：始终优先，覆盖危险对话、冒充用途和极端情绪场景。

5. 技术方案（保持低成本路线）

总体策略：尽量沿用原方案技术栈，只在“识别模式控制、方言素材处理、方言 persona、方言 TTS 增强”四个节点做增量改造。

5.1 总体架构

- 前端：Next.js Web App
- 后端：Python + FastAPI
- ASR：Faster Whisper 本地部署为主；必要时可为粤语场景保留云端接口兜底
- LLM：Gemini 2.5 Flash API（主）
- TTS：GPT-SoVITS V3 本地部署（主），优先保留中文/粤语增强可能性

- 数据库：PostgreSQL + pgvector
- 对象存储：Cloudflare R2 / 阿里云 OSS

5.2 双模识别方案（第一阶段落地重点）

模式	输入语言	实现策略	备注
普通话模式	普通话为主	Faster Whisper 常规转写	低成本、默认稳定
粤语模式	粤语为主	为 ASR 请求增加语言提示 / 粤语配置；必要时兜底到云端识别	首期重点支持
混合模式	普通话+粤语夹杂	首版不默认开放；内测阶段仅用于数据收集	避免识别不稳
失败回退	低置信度输入	前端提示复述或切换模式	降低误识别导致的出戏

5.3 方言声音输出方案（第三层目标）

目标定义：不是单纯“把中文文本念出来”，而是尽量保留亲人的方言音色、方言发音习惯和常用表达。首版以粤语/普通话场景优先。

- 模型：继续使用 GPT-SoVITS V3，本地部署，避免额外 TTS 订阅成本。
- 输入策略：生成前先由 LLM 输出带 dialect_style 的文本，再送入 TTS。
- 素材要求：建议累计 1–3 分钟以上清晰、同一说话人、带粤语覆盖的音频；5–10 秒仅可用于试验，不应作为稳定体验承诺。
- 训练前处理：去噪、切片、过滤静音、判定说话人纯度、标记普通话/粤语占比。
- 输出分级：A 级（方言素材充足，启用方言增强）；B 级（音色可用、方言不足，输出音色优先）；C 级（素材不足，仅试用，不推荐上线）。

5.4 关键服务拆分

服务	职责	是否新加	说明
asr_service	语音转文字	否（增强）	增加普通话/粤语模式参数与低置信度回退
persona_service	人设拼装	是	拼接 identity/style/dialect_style/comfort_rules
memory_service	分层记忆检索	否（增强）	在现有向量检索上增加 metadata 过滤
tts_service	文字转亲人声音	否（增强）	增加方言素材评分与输出等级控制
safety_service	风控	是	处理冒充、高风险情

			绪、越权上传
quality_service	素材评分	是	检测可训练度与方言覆盖度

5.5 延迟与体验目标

- 录音结束到 ASR 文本：目标 < 1.5 秒
- LLM 首 token：目标 < 1.5 秒
- 首段 TTS 播放：目标 < 2 秒
- 总首响：尽量控制在 3–5 秒
- 首版优先保证稳定和自然，暂不追求电话级实时对话

6. 成本控制方案

维持原低成本路线，不引入高价商业 TTS 作为主方案。

组件	方案	月费用（估算）
ASR	Faster Whisper 本地部署；粤语特殊场景少量云端兜底	¥0 为主
LLM	Gemini 2.5 Flash API 免费额度	¥0
TTS	GPT-SoVITS V3 本地部署	¥0
检索	PostgreSQL + pgvector	¥0
对象存储	Cloudflare R2 / 阿里云 OSS	低成本
前后端部署	Vercel + fly.io / Railway / 本地	低成本

结论：在不大规模调用商业语音服务的前提下，MVP 仍可维持极低成本；真正增加的主要是工程复杂度，而不是订阅费用。

7. 风险、边界与风控机制

7.1 授权与用途边界

- 仅支持本人上传已故直系亲属素材；上传时需确认与被克隆对象关系和用途。
- 禁止上传在世且未授权者声音；禁止用于诈骗、冒充、恶搞或公众人物模仿。
- 声音模型与用户账号强绑定，不开放导出。

7.2 情绪安全机制

- 普通悲伤：维持角色陪伴与安慰。
- 强烈绝望/自责：弱化沉浸式角色，转为现实支持性语言。
- 自伤/自杀信号：停止角色扮演，提示联系现实家人、朋友或专业援助。

7.3 方言相关失败场景

失败场景	原因	处理策略
粤语识别错误	夹杂输入、语速过快、噪音大	提示切换粤语模式或重新录音
方言声音不自然	素材短、覆盖不足、说话人不纯	降低到音色优先模式并提示补充素材
用户期待过高	误以为系统可完全还原亲人	在上传、训练、试听各阶段反复说明 AI 模拟边界
输出引发不适	语气像但内容不像、或发音怪异	允许一键反馈、屏蔽某些表达并重训练 persona

8. 开发路线图（修订版）

阶段	周期	主要任务	目标
Phase 1	第 1–2 周	搭建前后端、数据库、Gemini 对话链路、基础记忆结构	跑通普通话对话
Phase 2	第 3–4 周	接入 Faster Whisper、支持普通话/粤语双模识别、素材评分	跑通双模识别
Phase 3	第 5–6 周	接入 GPT-SoVITS、加入方言 persona、完成方言输出分级	完成方言增强语音输出
Phase 4	第 7–8 周	UI 打磨、试听、失败提示、安全策略、内测反馈	可做小规模测试

9. 上线前验收标准

- 用户能成功建立单角色档案，并完成至少一次可接受的试听。
- 普通话模式稳定可用；粤语模式在目标测试集上达到可接受识别率。
- 当方言素材不足时，系统会明确降级，不输出虚假“高保真方言”承诺。
- 高风险情绪与越权使用场景能被 safety_service 正确拦截或降级。
- 至少收集一轮内测用户对“像不像本人 / 是否不适 / 是否愿意继续用”的反馈数据。

10. 一句话版本

「余声」v0.2 的目标不是在第一天就“完美复活”亲人，而是在低成本技术栈下，先安全地做出一个能听懂普通话/粤语、并尽量用亲人方言声音回应的纪念型语音陪伴产品。